Agente de calidad del aire del Valle de Aburrá

Naive Bayes y HMM propios + agente LLM con RAG + dashboard

Juan Tomás Macías Yepes
Carlos Mario Arroyave Aguirre
SI3003 – Inteligencia Artificial
EAFIT 2026-1
Grupo: Jueves

Noviembre de 2026

1. Problema

El Valle de Aburrá vive episodios de contaminación por $PM_{2.5}$, sobre todo entre febrero y abril y, en menor medida, en octubre y noviembre. Para un ciudadano no es obvio qué significa un valor en $\mu g/m^3$, qué tan probable es que mañana empeore ni qué recomienda la norma. Construimos un MVP que combina tres piezas: (i) modelos clásicos propios que estiman la categoría del día siguiente; (ii) un agente LLM con *tool calling* y RAG que responde en lenguaje natural citando normativa; y (iii) un dashboard que integra mapa, serie de tiempo, predicción y chat.

2. Datos

- **Fuente principal:** IDEAM-SISAIRE (datos.gov.co, conjunto `g4t8-zkc3`), con $PM_{2.5}$ horario medido por las estaciones del AMVA entre 2020 y 2025 (1 046 932 filas). El portal del AMVA respondió 502 y SIATA solo publica una ventana de un año (jul-2023 a jul-2024), que usamos para rellenar 46 117 horas.
- **Meteorología:** lluvia y viento diarios de Open-Meteo (reanálisis ERA5, *modelado*), en 8 celdas de 0,1°.
- **Limpieza:** promedio de 24 h solo con ≥ 75 % de horas válidas (1 922 días-estación descartados). Encontramos una **inconsistencia de escala** en SISAIRE: varias estaciones reportan en 2020–2023 medianas de 60 a 117 $\mu g/m^3$, frente a $\sim$15 en las vecinas. Si no se filtra, aparecen cientos de días "críticos" falsos. Descartamos 715 estación-mes con dos reglas: mediana mensual mayor a 3 veces el P25 regional del mes, o mayor a 3 veces la mediana propia de la estación en 2024–2025.
- **Resultado:** 25 estaciones y 28 304 días-estación.
- **Clases del proyecto:** `normal` ($\leq 37\,\mu g/m^3$, el límite diario de la Res. 2254/2017 desde jul-2018), `alerta` (38–55) y `critico` (≥ 56). Por rangos, coinciden con los niveles de Prevención y de Alerta/Emergencia de la Tabla 4 de la resolución, pero son una simplificación nuestra, no una declaratoria.
- **Desbalance extremo:** 27 996 días normal, 307 alerta y **1** crítico. Las alertas se concentran en feb–abr (EDA en `notebooks/01_eda.ipynb`).

3. Parte 1: modelos clásicos (implementación propia en NumPy)

Naive Bayes categórico (`src/models/naive_bayes.py`). Predice la clase de $t+1$ a partir de features del día t:

- nivel de $PM_{2.5}$ (5 rangos);
- tendencia frente a $t-1$;
- terciles de lluvia y viento, calculados solo con entrenamiento;
- mes y día de la semana de $t+1$ (calendario conocido de antemano).

Con suavizado de Laplace y en log-probabilidades:

$$\log P(y{=}k \mid \mathbf{x}) = \log P(y{=}k) + \sum_j \log \frac{N_{k,j,x_j} + \alpha}{N_k + \alpha V_j} - \log Z.$$

El prior empírico se suaviza (`prior_alpha = 1`) porque en entrenamiento no hay ningún día crítico. Un test verifica que `predict_proba` coincide con `sklearn.CategoricalNB` (tolerancia 10^{-6}).

HMM gaussiano de 3 estados sobre $x_t = \log(PM_{2.5})$ (`src/models/hmm.py`):

- forward escalado, backward, Baum-Welch sobre las 25 series y Viterbi;

- los días faltantes se tratan como observaciones ausentes ($b_s(x_t) = 1$);
- la predicción a un paso es $P(z_{t+1} \mid x_{1:t}) = A^\top \alpha_t$, y se convierte en probabilidad de clase integrando la gaussiana de cada estado sobre los rangos de $PM_{2.5}$.

Los tests comprueban que la log-verosimilitud sea monótona y que se recuperen los parámetros en datos simulados.

Protocolo. Partición temporal por fecha objetivo: entrenamiento 2020–2023 y prueba 2024–2025. La prueba abarca dos años porque 2025 solo tiene 6 días de alerta, mientras que 2024 incluye el episodio de marzo. Los hiperparámetros del NB ($\alpha \in \{0{,}5; 1; 2; 5\}$, prior empírico/uniforme y umbral de decisión) se eligieron con validación de ventana expandible en 2021, 2022 y 2023. Resultado: $\alpha = 5$, prior empírico, argmax. Líneas base: persistencia y climatología mensual.

Tabla 1: Prueba 2024–2025 ($n = 14\,744$). Episodio = alerta o crítico. El F1 macro incluye las 3 clases; "crítico" tiene un solo caso en prueba.

Modelo	Accuracy	F1 macro	Recall episodios	Precisión episodios	Log-loss
Persistencia	0,987	**0,511**	**0,549**	0,543	—
Climatología mensual	0,986	0,331	0,000	—	0,065
Naive Bayes	**0,989**	0,505	0,451	**0,628**	**0,039**
HMM (1 paso)	0,986	0,331	0,000	—	0,058

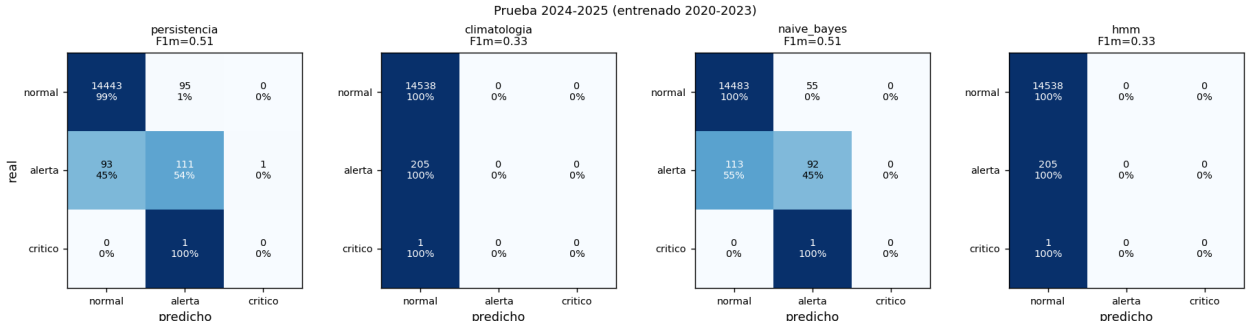


Figura 1: Matrices de confusión en prueba (normalizadas por fila).

Interpretación.

- **El NB no supera a la persistencia en F1 macro; empatan.** El NB acierta más cuando anuncia un episodio (precisión 0,63 vs 0,54) pero detecta menos (recall 0,45 vs 0,55). Su aporte real son probabilidades útiles: log-loss 0,039 frente a 0,065 de la climatología.
- **Por qué no gana:** el $PM_{2.5}$ es muy persistente ($\rho = 0{,}74$ entre días consecutivos), y la meteorología disponible es del día t, de baja resolución y poco correlacionada con el $PM_{2.5}$ de mañana ($|\rho| < 0{,}1$).
- **Ajuste descartado:** discretizar el nivel de hoy más fino cerca de 37 µg/m^3 no mejoró la validación, así que no se adoptó (no ajustamos sobre prueba).
- **HMM:** sus estados quedaron en niveles de fondo (∼12, 17 y 25 µg/m^3), no en episodios, porque el entrenamiento casi no tiene alertas (74 de 12 662). Como clasificador equivale a la climatología, aunque con mejor log-loss. En el dashboard lo usamos como descriptor del estado latente.

4. Parte 2: agente LLM con RAG

Loop (`src/agent/loop.py`), escrito sin frameworks:

1. Arma los mensajes: *system prompt*, contexto del dashboard (estación y fecha), historial y pregunta.
2. Llama al LLM con 4 herramientas en JSON Schema y ejecuta las que pida.
3. Devuelve el resultado como mensajes `tool` y repite hasta la respuesta final o $T_{\text{máx}} = 6$; en la última iteración quita las herramientas para forzar una respuesta.

Los errores de herramientas vuelven como `{"error": ...}` y el LLM tiene un reintento único que respeta `retry-after` ante un 429. Cada paso queda en una traza (herramienta, argumentos, resumen, latencia) que el dashboard muestra.

Herramientas: `get_pm25` (dato diario, ICA y últimos 7 días); `predict_tomorrow` (NB y HMM, con features usadas y desempeño en prueba); `search_docs` (RAG); `list_stations`.

RAG (`src/rag/`). Corpus de 7 PDF: Res. 2254/2017, Acuerdo Metropolitano 15 (POECA), resolución de episodio 2022, hoja metodológica ICA del IDEAM, resumen de las guías OMS 2021, presentación OPS y plan POECA de La Estrella. Los fragmentos tienen ∼350 palabras con 60 de solapamiento, siempre dentro de una página, para que la cita `[fuente, p. N]` sea exacta. Usa `paraphrase-multilingual-MiniLM-L12-v2` con FAISS (coseno, umbral 0,40) y BM25 como respaldo sin internet.

Hallazgos en las primeras pruebas y correcciones:

- el modelo agregó recomendaciones sin respaldo (mascarilla N95, hidratación) → el prompt exige que cada recomendación salga de un fragmento, con su cita al lado;
- atribuyó un texto de La Estrella al Acuerdo 15 → cada fragmento trae un campo `cita` para copiar literal, y el loop **verifica** que toda cita de la respuesta corresponda a un fragmento recuperado.

5. Evaluación del agente

`eval/questions.yaml` tiene 14 preguntas fijas: dato puntual (2), predicción (2, una con el contexto del dashboard), normativa (2), salud (2), cadenas de 2 y 3 herramientas, estación inexistente, fecha sin datos, pregunta fuera de alcance y una solicitud de consejo médico. `python eval/run_eval.py` las corre todas y califica cada una **automáticamente**. Una respuesta es correcta si se cumplen todas estas condiciones: usó las herramientas esperadas; contiene los datos mínimos verificados de antemano; tiene citas, si se requieren, y todas corresponden a fragmentos realmente recuperados; y no hubo error del LLM.

Tabla 2: Resultados de la evaluación (`openai/gpt-oss-120b` en Groq).

Corrida	Correctas	Herramientas esperadas	Citas correctas
1	12/14 (86 %)	14/14	6/6
2, tras corregir el prompt	**13/14 (93 %)**	14/14	6/6

Análisis de fallos (corrida 1).

- *Dato puntual sin valor* (prompt): dio la categoría pero no los µg/m^3 → regla "incluye siempre el valor, la fecha y la categoría".
- *Niveles de declaratoria* (corpus + prompt): usó la tabla del Acuerdo 15, que adopta los cortes de la EPA de 2012, e inventó una fila de "prevención" → reglas de no completar tablas y de priorizar la norma nacional cuando las fuentes difieren.

En la corrida 2 ya no inventa la fila y declara que no tiene respaldo para "prevención", pero sigue sin dar 38/56/151. El fragmento correcto (Res. 2254, p. 5) **sí se recupera**: el problema es el OCR de esa tabla (`PM2.s'* 24 horas 38-55 56-150 2::151`). Queda como fallo reportado. La solución sería reemplazar la copia escaneada por el texto oficial en HTML; no ajustamos la pregunta para que pase. Latencia mediana ≈ 11 s; los picos de hasta ∼100 s se deben a las esperas por el límite de tokens por minuto del plan gratuito.

6. Dashboard

`app.py` (Streamlit + Plotly) muestra:

- mapa de estaciones coloreado por la categoría ICA del día elegido;
- serie de tiempo con bandas ICA, la línea de 37 µg/m^3 y una franja con el estado latente filtrado del HMM;
- tarjeta de predicción con barras de probabilidad (NB y HMM) y desempeño en prueba;
- chat que recibe la estación y fecha seleccionadas, con un expander "¿Cómo llegó a esta respuesta?" que muestra herramientas, citas y citas no verificadas.

Arranca sin internet y sin API key (chat desactivado con aviso), y lo prueban `tests/test_app.py` con `AppTest`.

7. Limitaciones

- Solo hay un día crítico en seis años y ∼1 % de días de alerta: las métricas de episodios dependen sobre todo del episodio de feb–abr de 2024.
- En 2020–2023 falta la mitad de las estaciones por la inconsistencia de SISAIRE, y 2020 incluye la cuarentena por COVID-19.
- La meteorología es reanálisis de ∼10 km y del día t; un pronóstico meteorológico de $t + 1$ mejoraría la predicción.

- El POECA del corpus es el Acuerdo 15 (versión SICLAS), no el Acuerdo 04 de 2018 vigente, que no pudimos descargar. La Res. 2254 viene de una copia con OCR.
- La evaluación del agente es automática, con criterios por palabras clave: no mide la calidad de la redacción y puede castigar respuestas correctas formuladas de otra manera.
- El plan gratuito de Groq limita los tokens por minuto; la app maneja el 429, pero hay que espaciar las preguntas.

Herramienta académica: no es consejo médico ni aviso oficial.
Uso de IA generativa declarado en `docs/declaracion_ia.md`.